



華中科技大學


Huazhong University of Science and Technology

华中科技大学人工智能与 自动化学院

专业：控制科学与工程
智能系统与系统工程系

应聘人： 郝国凯

1. 个人基本信息



华中科技大学
HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY



姓名： 郝国凯

籍贯： 河南

研究方向： 强化学习、智能决策、优化控制、多智能体协同

专业： 控制科学与工程

政治面貌： 中共党员

一作/学生一作，发表学术论文7篇
其中IEEE trans 5篇：



获得学科竞赛奖励7项
其中国家一等奖2项：



获得荣誉称号若干：



国家奖学金
三好研究生
优秀研究生干部
优秀共产党员
优秀党务工作者
优秀志愿者
优秀研究生党支部书记……

2. 什么是强化学习



什么是强化学习，强化学习能干什么？

➤ 什么是强化学习：


智能体通过不断观测环境 → 做出决策 → 获取反馈 → 调整策略，逐步学习如何获得更高的长期收益。

➤ 强化学习能做什么（优化、控制、规划、决策）：

- 玩游戏：AlphaGo 学习围棋决策并战胜人类冠军，OpenAI Five 学习团队协作并击败 Dota 2 职业战队。
- 开汽车：根据道路、车辆和障碍物状态，学习跟车、变道、避障等驾驶决策
- 无人机协同搜索：多架无人机根据各自位置和探测信息，自主分工、协同搜索，并持续跟踪移动目标。
- 无人艇自主航行：根据航道、障碍物和其他船只的运动状态，自主规划航线并实时避碰，实现安全航行。

➤ 一句话描述：

只要一个问题具有“状态 → 决策 → 反馈”的持续交互过程，就可以考虑利用强化学习寻找高收益的决策策略。



2. 个人主要研究工作



➤ Reinforcement Learning (强化学习)



理想中的RL智能体




实际得到的RL智能体

原因分析

学习效率低，环境不确定性强，安全性难以保障
泛化能力不足，多智能体协同困难

个人
主要
研究
方向



1. 高效策略学习与优化

2. 不确定性环境下的鲁棒决策


3. 安全约束下的可靠学习

4. 跨场景泛化与快速适应


5. 多智能体协同决策与学习

通过网络结构，决策空间，算法原理的设计提升RL学习效率


- 设计更符合实际问题的网络结构，增强信息提取能力：
实际电力系统本身为图结构，电力节点之间仅能通过输电线路产生相互影响。采用图神经网络可以充分的利用连接矩阵进行信息聚合。
- 设计更符合实际问题的决策空间，降低动作空间维度：
通过环路编码方式，可将动作空间维度缩小近万倍。
- 设计更符合问题特性的算法，算法具有针对性：
通过多臂老虎机算法设计，使算法更具有针对性，简单和高效。




(1) Theoretical basis



(2) Algorithm







(3) Framework



通过与其他算法相结合提升RL学习效率

- 通过PPO与演化计算协同，提升探索能力与收敛效率：
针对训练后PPO在线探索能力有限、传统PSO寻优速度较慢的问题，以PPO输出的较优方案引导PSO前期搜索，再由PSO自主探索并进一步优化，实现二者优势互补，**加快算法收敛，提高寻优性能与鲁棒性。**
- 通过动作空间解耦与知识嵌入，提升RL学习效率及小样本场景决策能力：
将复杂时序决策交由PPO学习、韧性决策由领域知识指导、线性决策由混合整数规划求解，**缩减RL动作空间、降低策略学习难度**；同时利用先验知识弥低概率场景样本不足的问题，提升极端场景下的决策性能与系统韧性。



- 融合多目标仿真优化，实现RL多目标求解：
将DQN与多目标细菌觅食算法结合，利用RL引导种群搜索方向，提升**多目标优化**的寻优效率与Pareto解质量。

2.2 不确定性环境下的鲁棒决策



通过鲁棒强化学习提升强化学习应对不确定性能力

➤ 传统强化学习优化累计期望奖励:


传统强化学习的目标函数为最大化累计期望奖励，相当于优化均值但仍可能在部分场景下出现一些**极端情况**，使得策略效果很差。

➤ 通过鲁棒RL优化策略最差情况下的性能表现:

鲁棒强化学习通过优化策略在不确定性集中最差的性能表现，不断提高控制策略在**最不利条件下的性能**，提高控制策略**性能下限**。



➤ 更保守的训练性能，更良好的测试性能:

训练阶段优化性能下限，即**兜底性能**，效果较为保守。测试阶段性能更为良好。



$$\mathcal{T}_R(Q_{\pi_\theta}(s_t, a_t)) = \mathcal{R}(s_t, a_t) + \gamma \inf_{P \in \mathcal{M}} \mathbb{E}_{s_{t+1} \sim P} [V_{\pi_\theta}(s_{t+1})].$$

$$\mathcal{P}_{\theta_{\text{env}}^{\text{rb}}} = \arg \min_{\mathcal{P}_{\theta_{\text{env}}} \in \mathcal{M}} V_{\pi}(\mathcal{P}_{\theta_{\text{env}}}(s_t, a_t))$$



通过混合整数线性规划与Lyapunov安全策略优化保证策略安全

➤ 传统安全强化学习难以保证算法安全:





实际传统强化学习大多通过添加惩罚项来增加策略安全性, **缺乏理论依据**, 惩罚因子**大小难以确定**, 且属于**事后修正学习**。

➤ 通过混合整数线性规划对动作进行安全映射与评估:

通过混合整数线性规划对当前动作的安全性能进行评估, 对不安全动作将其映射至安全域, 在**动作层面**保证算法安全性。

➤ 通过Lyapunov安全策略优化保证策略更新的安全性:

通过多Lyapunov安全策略优化构建策略安全集, 限制策略更新仅在安全集合内更新, 从而在**策略层面**保证算法安全性。




2.4 提升跨场景泛化与迁移能力



研究能够跨场景应用的强化学习算法。


- **现存问题：**传统RL通常在单一任务上进行训练，换到新环境后表现不佳。而许多场景要求智能体能够**快速适应复杂动态环境**。
- **元强化学习：**通过训练阶段接触大量相关任务，从中提取共性知识，在面对各种任务与新任务时可以**快速调整策略**。
- **经典应用场景：**例如上图中，四足机器人需要快速适应在不同场景下的行走策略。从而实现在各种场景下的稳定行走。



识别当前所处的物理运行情境

提炼能够表征任务差异的隐变量

利用隐变量驱动策略快速适应




基于不确定性预测信息的元强化学习框架

- **当前研究不足：**传统 Meta-RL 通常依赖二次训练或大量交互数据推断任务模态，难以实现快速部署与即时泛化。
- **提出方法：**基于不确定性预测信息推断任务模态，通过双流推断网络学习任务隐变量，结合自适应信息瓶颈提高泛化能力，融合MDP实现 Meta-RL 控制。
- **核心优势：**无需二次训练，通过预测与实际信息快速识别任务模态，实现上线即用的跨任务自适应控制。


多智能体强化学习算法——以序列模型视角看待多智能体学习（CTCE）：

➤ 多智能体强化学习：通过将多智能体强化学习构建为序列模型实现多智能体协同合作控制：

基于多智能体优势分解理论，将联合动作策略转化为逐智能体的自回归序列决策问题，并引入Transformer Encoder-Decoder架构。Encoder对多智能体观测进行编码，通过Attention建模智能体间交互关系，生成交互感知的多智能体潜在表示，并用于价值评估。Decoder结合前序智能体动作，通过Masked Attention和Cross Attention逐步生成各智能体动作。该方法将多智能体强化学习转化为序列建模问题，在CTDE框架下实现高效的多智能体协同控制。




多智能体算法结构示意图




多智能体强化学习算法——以扩散模型视角看待多智能体学习 (CTDE) :


- 扩散模型：通过学习从存噪声中逐步恢复出与训练数据分布高度一致的逼真样本。




- 这种多步非线性修正，使简单的高斯噪声能够被逐渐“塑形”为复杂、多峰的目标分布。（我们可以将猫的图片视为极其复杂的多峰分布）



- 多智能体任务往往存在多种可行的协同模式，扩散策略通过表征复杂、多模态的动作分布，能够**保留并探索更多潜在的高质量协同策略**。



- 将扩散策略引入多智能体强化学习中的Actor，从高斯噪声出发，通过**多步迭代去噪生成动作，增强复杂、多模态策略分布的表达能力**；结合CTDE框架，利用Centralized Joint Distributional Critic 对联合动作进行全局价值评估，并统一指导各智能体策略更新，**实现协同学习**。



多智能体观测

扩散策略生成H步迭代去噪

联合动作生成


环境交互经验数据采集

中心化价值分布评估

同步扩散策略优化

多智能体强化学习算法——以对抗视角看待多智能体学习 (CTDE) :


➤ 核心问题一：战术层-如何实现大规模异构多智能体协同对抗学习：



- 异构智能体策略建模：智能体观测→CNN/MLP→LSTM时序建模→统一策略特征→干什么/怎么干/对谁干
- 稳定策略学习：Dual-clip PPO+ Multi-Head Value
- 面向爆炸组合的课程化群体协同训练：固定阵容训练→多教师知识蒸馏→随机阵容联合训练

➤ 核心问题二：战略层-如何实现大规模组合博弈中的阵容规划：

- 阵容胜率预测器：输入5v5阵容→输出阵容胜率
- 阵容规划价值网络：输入当前阵容信息→输出当前阵容的长期博弈价值
- 基于MCTS的阵容规划：选择→扩展→价值网络评估→反向传播→确定当前最优英雄选择



3. 学生工作与生活




华中科技大学
HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

长期参与学生工作，多次举办学生活动，多次参与抗疫等各种志愿活动。


- 开展博资考知识点讲解会议，校内博士累计观看次数达526次。
- 疫情期间，多次参加各种抗疫志愿者活动。
- 组织开展班级内学术交流会议。院内新生科研入门分享会。
- 在2023年、2024年参加学院迎新大会，负责为新生讲解选课系统。



个人生活方面:



热爱健身，平均每周两次，已坚持三年多。



喜欢规律且简单的生活方式，能够将主要时间与精力专注投入工作。

谢谢聆听！
Thank you!

